

Misurazione Implicita in Psicologia: Un approccio diverso per l'analisi dei dati IAT

Ottavia M. Epifania, Ph.D.
`ottavia.epifania@unipd.it`

18 luglio 2024, Padova

Master di II Livello
Psicologia quantitativa: Misurazione, valutazione e analisi di
variabili psicosociali


1 Look at the data!

2 Una possibile soluzione

- Variabili latenti

3 In pratica

- Step preparativi
- Stima dei modelli
- Model comparison
- Estrarre le stime del modello vincente



I rispondenti sono fattori random

Campione prelevato da una popolazione più ampia

È necessario riconoscere la variabilità del campionamento

I risultati possono essere generalizzati ad altri rispondenti appartenenti alla stessa popolazione

I rispondenti sono fattori random

Campione prelevato da una popolazione più ampia

È necessario riconoscere la variabilità del campionamento

I risultati possono essere generalizzati ad altri rispondenti appartenenti alla stessa popolazione

Gli stimoli sono fattori fissi

Presi come intera popolazione

Non c'è variabilità del campionamento

Non è necessario generalizzare i risultati perché gli stimoli sono la popolazione


Gli stimoli sono un campione delle rispettive categorie di appartenenza:

12 stimoli delle categorie target

Volti di persone Bianche



Volti di persone Nere



16 stimuli attributo

Attributi positivi

Good, laughter, pleasure, glory, peace,
happy, joy, love

Attributi negativi

Evil, bad, horrible, terrible, nasty, pain,
failure, hate

Generalizzabilità

La generalizzabilità è limitata al set specifico di stimoli utilizzato nell'esperimento

I risultati possono essere generalizzati se e solo se viene utilizzato esattamente lo stesso set di stimoli

Generalizzabilità

La generalizzabilità è limitata al set specifico di stimoli utilizzato nell'esperimento

I risultati possono essere generalizzati se e solo se viene utilizzato esattamente lo stesso set di stimoli

Robustezza dei risultati

La variabilità casuale a livello di stimolo potrebbe aumentare la probabilità di commettere errori di Tipo I

La media degli stimoli per ottenere punteggi a livello di persona porta a stime distorte a causa del rumore nei dati

Generalizzabilità

La generalizzabilità è limitata al set specifico di stimoli utilizzato nell'esperimento

I risultati possono essere generalizzati se e solo se viene utilizzato esattamente lo stesso set di stimoli

Robustezza dei risultati

La variabilità casuale a livello di stimolo potrebbe aumentare la probabilità di commettere errori di Tipo I

La media degli stimoli per ottenere punteggi a livello di persona porta a stime distorte a causa del rumore nei dati

Perdita di informazione

Non viene considerata tutta la variabilità né tutte le informazioni che possono essere ottenute da essa

Ogni stimolo è considerato come se fosse ugualmente informativo

- 1 Look at the data!
- 2 Una possibile soluzione
 - Variabili latenti
- 3 In pratica
 - Step preparativi
 - Stima dei modelli
 - Model comparison
 - Estrarre le stime del modello vincente

The supermodel(s)

Linear Mixed-Effects Models (LMMs)

-  Considerare (potenzialmente) tutte le fonti di variabilità e dipendenza
-  Raccogliere informazioni a livello di stimolo
-  Stimare i modelli di Rasch e log-normali

Epifania, O. M., Robusto, E., & Anselmi, P. (2021). Rasch gone mixed: A mixed model approach to the Implicit Association Test. *Testing, Psychometrics, Methodology in Applied Psychology*, 28, 467–483. doi: 10.4473/TPM28.4.5

Effetti e fattori random

Combinazione lineare dei predittori in un modello lineare:

$$\eta = X\beta,$$

dove β indica i coefficienti dell'intercetta fissa e della(e) pendenza(e) fissa, e X è la matrice del modello.


Combinazione lineare dei predittori in un modello lineare ad effetti misti (LMM):

$$\eta = X\beta + Zd,$$


dove Z è la matrice e d è il vettore degli effetti casuali (non parametri!)

Best Linear Unbiased Predictors

Modelli Generalizzati Lineari (GLM) per risposte dicomtomiche



Modelli Generalizzati Lineari (GLM) per risposte dicomtomiche



Logit link function g :
 $g(\eta_{ps}) = \log\left(\frac{\mu_{ps}}{1-\mu_{ps}}\right)$

Inverse g^{-1}

$$g^{-1} = \frac{\exp(\eta_{ps})}{1+\exp(\eta_{ps})}$$

Il modello di Rasch

$$P(x_{ps} = 1 | \theta_p, b_s) = \frac{\exp(\theta_p - b_s)}{1 + \exp(\theta_p - b_s)}$$

θ_p : Abilità del soggetto p

b_s : difficoltà dello stimolo s

Il modello di Rasch

$$P(x_{ps} = 1 | \theta_p, b_s) = \frac{\exp(\theta_p - b_s)}{1 + \exp(\theta_p - b_s)}$$

θ_p : Abilità del soggetto p

b_s : difficoltà dello stimolo s

Standard

GLM

$$P(x_{ps} = 1) = \frac{\exp(\theta_p - b_s)}{1 + \exp(\theta_p - b_s)}$$

$$P(x_{ps} = 1) = \frac{\exp(\theta_p + b_s)}{1 + \exp(\theta_p + b_s)}$$

Il modello di Rasch

$$P(x_{ps} = 1 | \theta_p, b_s) = \frac{\exp(\theta_p - b_s)}{1 + \exp(\theta_p - b_s)}$$

θ_p : Abilità del soggetto p

b_s : difficoltà dello stimolo s

Standard

$$P(x_{ps} = 1) = \frac{\exp(\theta_p - b_s)}{1 + \exp(\theta_p - b_s)}$$

GLM

$$P(x_{ps} = 1) = \frac{\exp(\theta_p + b_s)}{1 + \exp(\theta_p + b_s)}$$

E i tempi di risposta?

Modello log-normale

Standard

$$f(t_{ps}) = \delta_s - \tau_p + \varepsilon$$

LM

$$f(t_{ps}) = \delta_s + \tau_p + \varepsilon$$

N.B.

I tempi di risposta vanno log-trasformati

E i tempi di risposta?

Modello log-normale

Standard

$$f(t_{ps}) = \delta_s - \tau_p + \varepsilon$$

LM

$$f(t_{ps}) = \delta_s + \tau_p + \varepsilon$$

N.B.

I tempi di risposta vanno log-trasformati

La risposta attesa y per l'osservazione $i = 1, \dots, I$ del rispondente $p = 1, \dots, P$ allo stimolo $s = 1, \dots, S$ nella condizione $c = 1, \dots, C$:

Modello 1:

$$y_i = \alpha + \beta_c X_c + \alpha_{p[i]} + \alpha_{s[i]} + \varepsilon_i$$

$$\alpha_p \sim \mathcal{N}(0, \sigma_p^2),$$

$$\alpha_s \sim \mathcal{N}(0, \sigma_s^2).$$

Effetti Fissi

Modello 2:

$$y_i = \alpha + \beta_c X_c + \alpha_{p[i]} + \beta_{s[i]} c_i + \varepsilon_i$$

$$\alpha_p \sim \mathcal{N}(0, \sigma_p^2),$$

$$\beta_s \sim \mathcal{MVN}(0, \Sigma_{sc}).$$

Effetti-random

Modello 3:

$$y_i = \alpha + \beta_c X_c + \alpha_{s[i]} + \beta_{p[i]} c_i + \varepsilon_i$$

$$\alpha_s \sim \mathcal{N}(0, \sigma_s^2),$$

$$\beta_p \sim \mathcal{MVN}(0, \Sigma_{pc}).$$

Accuratezza: $\epsilon \sim \text{Logistic}(0, \sigma^2)$

Log-tempi: $\epsilon \sim \mathcal{N}(0, \sigma^2)$

Parametrizzazioni

Modelli sulle accuratezza (stime simil Rasch):

	Respondent	Stimulus
Model 1	Overall (θ_p)	Overall (b_s)
Model 2	Overall (θ_p)	Condition-specific (b_{sc})
Model 3	Condition-specific (θ_{pc})	Overall (b_s)

Modelli sui log-tempi (stime del modello log-normale):

	Respondent	Stimulus
Model 1	Overall (τ_p)	Overall (δ_s)
Model 2	Overall (τ_p)	Condition-specific (δ_{sc})
Model 3	Condition-specific (τ_{pc})	Overall (δ_s)

- 1 Look at the data!
- 2 Una possibile soluzione
 - Variabili latenti
- 3 In pratica
 - Step preparativi
 - Stima dei modelli
 - Model comparison
 - Estrarre le stime del modello vincente

Questi modelli possono essere stimati in R con il pacchetto `lme4`

```
install.packages("lme4") # per stimare i modelli
install.packages("ggplot2") # per fare i grafici
install.packages("car") # per preprocessing
library(lme4)
library(ggplot2)
```

Il data set su cui faremo questa esercitazione è disponibile a questa pagina: <https://ottaviae.github.io/DscoreApp/> (Sottosezione “Data”). Possono essere importati usando questo codice

```
my_url = "https://ottaviae.github.io/DscoreApp/raceAPP.csv"
iat_data = read.csv(url(my_url))
```

Un po' di ordine

```
# sistema l'etichetta di uno stimolo
temp = iat_data[iat_data$stimoli %in% "felicit\xe0", ]
iat_data = iat_data[!iat_data$stimoli %in% "felicit\xe0", ]
temp$stimoli = "felic"
iat_data = rbind(iat_data, temp)

# seleziona solo le colonne su cui facciamo le analisi
iat_data = iat_data[, c("participant", "blockcode", "stimoli", "latera
# rinomina le colonne in modo che siano uguali per tutt3
colnames(iat_data)[2:3] = c("condition", "stimuli")
# rinomina le condizioni
iat_data$condition = car::recode(iat_data$condition,
''Whitegood' = 'WGBB';
'Whitebad' = 'BGWB'")
```

Modello 1

$$y_i = \alpha + \beta_c X_c + \alpha_{p[i]} + \alpha_{s[i]} + \varepsilon_i$$

Accuratezze:

```
iat_accuracy1 = glmer(correct ~ 0 + condition + (1|participant) +  
  (1|stimuli),  
  data = iat_data,  
  family = "binomial")
```

Log-tempi:

```
iat_time1 = lmer(log(latency) ~ 0 + condition + (1|participant) +  
  (1|stimuli),  
  REML = FALSE,  
  data = iat_data)  
summary(iat_time1)
```

Modello 2

$$y_i = \alpha + \beta_c X_c + \alpha_{p[i]} + \beta_{s[i]} c_i + \varepsilon_i$$

Accuratezze:

```
iat_accuracy2 = glmer(correct ~ 0 + condition + (1|participant) +  
  (0 + condition|stimuli),  
  data = iat_data,  
  family = "binomial")
```

Log-tempi:

```
iat_time2 = lmer(log(latency) ~ 0 + condition + (1|participant) +  
  (0 + condition |stimuli),  
  REML = FALSE,  
  data = iat_data)
```

Modello 3

$$y_i = \alpha + \beta_c X_c + \alpha_{s[i]} + \beta_{p[i]} c_i + \varepsilon_i$$

Accuratezze:

```
iat_accuracy3 = glmer(correct ~ 0 + condition +  
  (0 + condition|participant) + (1|stimuli),  
  data = iat_data,  
  family = "binomial")
```

Log-tempi:

```
iat_time3 = lmer(log(latency) ~ 0 + condition +  
  (0 + condition |participant) + (1|stimuli),  
  REML = FALSE,  
  data = iat_data)
```

Accuratezze

```
anova(iat_accuracy1, iat_accuracy2, iat_accuracy3)
```

```
> anova(iat_accuracy1, iat_accuracy2, iat_accuracy3)
Data: iat_data
Models:
iat_accuracy1: correct ~ 0 + condition + (1 | participant) + (1 | stimuli)
iat_accuracy2: correct ~ 0 + condition + (1 | participant) + (0 + condition | stimuli)
iat_accuracy3: correct ~ 0 + condition + (0 + condition | participant) + (1 | stimuli)
      npar      AIC      BIC logLik deviance  Chisq Df Pr(>Chisq)
iat_accuracy1      4 4144.3 4172.1 -2068.1   4136.3
iat_accuracy2      6 4141.3 4183.1 -2064.7   4129.3 6.9271  2    0.03132 *
iat_accuracy3      6 4145.2 4187.0 -2066.6   4133.2 0.0000  0
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> |
```

The winner is...

```
> summary(iat_accuracy2)
```

```
Generalized linear mixed model fit by maximum likelihood (Laplace Approximation) ['glmerMod']
```

```
Family: binomial ( logit )
```

```
Formula: correct ~ 0 + condition + (1 | participant) + (0 + condition | stimuli)
```

```
Data: iat_data
```

AIC	BIC	logLik	deviance	df.resid
4141.3	4183.1	-2064.7	4129.3	7794

```
Scaled residuals:
```

Min	1Q	Median	3Q	Max
-8.8764	0.1679	0.2242	0.3401	0.9156

```
Random effects:
```

Groups	Name	Variance	Std.Dev.	Corr
participant	(Intercept)	0.26197	0.5118	
stimuli	conditionBGWB	0.13826	0.3718	
	conditionWGBB	0.06752	0.2598	0.17

```
Number of obs: 7800, groups: participant, 65; stimuli, 28
```

```
Fixed effects:
```

	Estimate	Std. Error	z value	Pr(> z)
conditionBGWB	2.0128	0.1080	18.63	<2e-16 ***
conditionWGBB	3.4182	0.1226	27.88	<2e-16 ***

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Correlation of Fixed Effects:
```

	cnBGWB
conditnWGBB	0.379

Per ottenere le proporzioni di risposte corrette nelle due condizioni:

$$\exp(\text{fixef}(\text{iat_accuracy2})) / (1 + \exp(\text{fixef}(\text{iat_accuracy2})))$$

Log-tempi

```
anova(iat_time1, iat_time2, iat_time3)
```

```
> anova(iat_time1, iat_time2, iat_time3)
Data: iat_data
Models:
iat_time1: log(latency) ~ 0 + condition + (1 | participant) + (1 | stimuli)
iat_time2: log(latency) ~ 0 + condition + (1 | participant) + (0 + condition | stimuli)
iat_time3: log(latency) ~ 0 + condition + (0 + condition | participant) + (1 | stimuli)
      npar    AIC    BIC logLik deviance   Chisq Df Pr(>Chisq)
iat_time1     5 6073.2 6108.0 -3031.6   6063.2
iat_time2     7 6061.4 6110.2 -3023.7   6047.4  15.743  2  0.0003815 ***
iat_time3     7 5657.2 5705.9 -2821.6   5643.2 404.249  0
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Attenzione! Il modello 2 non arriva a convergere

And the winner is...

```

> summary(iat_time3)
Linear mixed model fit by maximum likelihood ['lmerMod']
Formula: log(latency) ~ 0 + condition + (0 + condition | participant) + (1 | stimuli)
Data: iat_data

            AIC          BIC      logLik deviance df.resid
5657.2      5705.9     -2821.6    5643.2      7793

Scaled residuals:
    Min       1Q   Median       3Q      Max
-8.7743 -0.6415 -0.1647  0.4835  6.1439

Random effects:
 Groups      Name                Variance Std.Dev. Corr
participant conditionBGWB 0.046391 0.21539
              conditionWGBB 0.024304 0.15590 0.54
stimuli      (Intercept)    0.004419 0.06648
Residual                    0.114272 0.33804
Number of obs: 7800, groups: participant, 65; stimuli, 28

Fixed effects:
              Estimate Std. Error t value
conditionBGWB  6.83902    0.03002   227.8
conditionWGBB  6.50371    0.02369   274.5

Correlation of Fixed Effects:
      cnBGWB
conditnWGBB 0.618

```

Accuratezze


Abilità dei soggetti θ_p :

```
ab_iat = data.frame(sbj = rownames(coef(iat_accuracy2)$participant),
                    theta = coef(iat_accuracy2)$participant[,1])
```

```
# grafico
```

```
graph_theta_iat = ggplot(ab_iat,
                          aes(x = theta)) + geom_density()
```

```
graph_theta_iat
```



Accuratezze

Difficoltà degli item condizione-specifica b_{sc}

```
# effetti random con dev std
blup_easiness_iat = as.data.frame(ranef(iat_accuracy2,
                                     condVar = TRUE))

# effetti fissi
fixef_accuracy_iat = data.frame(term = names(fixef(iat_accuracy2)),
                                est = (fixef(iat_accuracy2)))

# unire effetti fissi ed effetti random
easiness_iat = merge(blup_easiness_iat, fixef_accuracy_iat)
colnames(easiness_iat) = c("Condition", "grpvar", "stimuli",
                          "blup", "se", "fix.est")


# calcola parametro dell'item
easiness_iat$b = with(easiness_iat, fix.est + blup)
```

Il plot

```
graph_b_ci = ggplot(easiness_iat,
  aes(x = b,      y = stimuli,  color = Condition)) +
  geom_point() +
  geom_errorbarh(aes(xmin = b - 1.96*se,
                    xmax= b + 1.96*se))

graph_b_ci
```

Estrarre le stime del modello vincente




Log-tempi

Velocità dei soggetti condizione-specifica τ_{pc}

```
speed_iat = coef(iat_time3)$participant[, -1]
# formato long
sp_iat = stack(speed_iat)
# rinomina le colonne
colnames(sp_iat) = c("tau", "condition")
graph_speed_iat = ggplot(sp_iat,
  aes(x = tau, fill = condition)) + geom_density()
```

Il risultato



Log-tempi

Time intensity degli item δ_s :

```
intensity_iat = data.frame(  
  stimulus = rownames(coef(iat_time3)$stimuli),  
  intensity = coef(iat_time3)$stimuli[,1])  
graph_delta_iat = ggplot(intensity_iat,  
  (aes(x = intensity, y = stimulus))) + geom_point()  
graph_delta_iat
```

